OPTİMİZASYON TEKNİKLERİ

CNN Tabanlı Vekil Modelleme ve Parçacık Sürü Optimizasyonu ile Global Optimizasyon

Sezgisel Optimizasyon Teknikleri — **Yusuf BARUT** • Adli Bilişim Mühendisliği

TEMEL PROBLEM

Karmaşık Optimizasyon Yüzeylerinin Analizi

Ackley ve Rastrigin gibi test fonksiyonları, optimizasyon algoritmalarını zorlamak için tasarlanmış yüzeylerdir. Binlerce **yerel minimum** (tuzak nokta) içeren bu fonksiyonlar, klasik yöntemlerin sınırlarını açıkça ortaya koyar.

Ackley: Geniş düz bölgeler ve dar bir dip noktası içeren, algoritmaları yanıltıcı bir yüzey.

Rastrigin: Binlerce eşit derinlikte periyodik çukur içeren, global minimumu bulmayı zorlaştıran yüzey.

Global Optimum Sorunu

Ackley ve Rastrigin fonksiyonları binlerce yerel minimum içerir. Algoritma en küçük çukura takılıp kalabilir ve gerçek global minimumu asla bulamaz.

Klasik Yöntemlerin Sınırı

Gradient tabanlı algoritmalar yalnızca yerel eğime bakar; bu tuzaklara düşer ve global çözümü kaçırır. Türev bilgisi, engebeli yüzeylerde yetersiz kalır.

Yüzey Karakteri

Bu fonksiyonlar birer **topografik harita** gibidir; eğimler, çukurlar ve tepeler uzamsal desenler oluşturur. Bu desenler makine öğrenimi ile öğrenilebilir.

ÇÖZÜM YAKLAŞIMI

Sezgisel Optimizasyon ve Global Arama

Meta-Sezgisel Yaklaşım Nedir?

Doğadaki süreçlerden ilham alan, **türev gerektirmeyen** esnek çözüm yöntemleridir. Fonksiyonun matematiksel yapısını bilmek zorunda değillerdir; yalnızca çıktı değerlerini değerlendirirler.

- Popülasyon tabanlı arama
- Rastgelelik ve determinizmin dengesi
- Yerel tuzaklardan kaçış kapasitesi

Global Arama Kapasitesi

Sezgisel algoritmalar rastgelelik ve tecrübeyi birleştirerek engebeli yüzeylerde global minimumu bulma yeteneğine sahiptir. Keşif (exploration) ve sömürüm (exploitation) arasındaki denge, başarının anahtarıdır.

Seçilen Algoritma: Parçacık Sürü Optimizasyonu (PSO) — basit yapısı, hızlı yakınsaması ve güçlü global arama kapasitesi ile bu çalışmanın temel motorudur.

ALGORITMA DETAYI

Parçacık Sürü Optimizasyonu (PSO) Mekanizması

PSO, kuş sürülerinin kolektif yiyecek arama stratejisinden ilham alır. Her parçacık hem kendi deneyimini hem de sürünün ortak bilgisini kullanarak hareket eder.

Pbest — Kişisel En İyi

Parçacığın kendi geçmişindeki en iyi konum. Bireysel hafıza bileşenidir; parçacığı kendi deneyimli olduğu iyi bölgelere çeker.

Gbest — Global En İyi

Tüm sürünün şimdiye kadar bulduğu en iyi konum. Kolektif hafıza bileşenidir; parçacıkları sürünün ortak keşfine yönlendirir.

Dinamik Hareket

Parçacıklar hız ve konumlarını Pbest ve Gbest'e göre günceller. Bu iki çekim kuvveti arasında denge kurarak global minimuma doğru akar.

KRITIK DARBOĞAZ

Hesaplama Maliyeti: PSO'nun En Büyük Zayıflığı

PSO güçlü bir algoritmadır, ancak her iterasyonda **gerçek fonksiyonu binlerce kez** hesaplamak zorundadır. Karmaşık optimizasyon problemlerinde bu durum süreci ciddi ölçüde yavaşlatır.

10K+

Fonksiyon Çağrısı

Tipik bir PSO çalışmasında gereken minimum fonksiyon değerlendirme sayısı

~95%

Hesaplama Süresi

Toplam çalışma süresinin fonksiyon değerlendirmelerine harcanan oranı

1000x

Hız Potansiyeli

Vekil model kullanımıyla elde edilebilecek teorik hızlanma faktörü

Kritik Soru: Fonksiyonu her seferinde hesaplamak yerine, onun davranışını "öğrenen" bir yapay zeka modeli kullanılabilir mi?

YAPAY ZEKA ÇÖZÜMÜ

Vekil Modelleme (Surrogate Modeling) ile Hızlanma

Vekil Model Nedir?

Vekil model, gerçek ve pahalı fonksiyonu **taklit eden** yapay bir zeka katmanıdır. Gerçek fonksiyon yerine bu model sorgulanır; böylece hesaplama yükü dramatik biçimde düşer.

Çalışma Prensibi

Öncelikle gerçek fonksiyondan bir miktar veri toplanır. Bu veriyle eğitilen model, yeni noktalarda fonksiyon değerini **tahmin eder**. PSO artık gerçek fonksiyona değil, bu hızlı tahmin modeline başvurur.

- Gerçek fonksiyon: yavaş, kesin
- Vekil model: hızlı, yaklaşık
- Hedef: ikisinin en iyi yönlerini birleştirmek

Hız Avantajı

Eğitilmiş bir ağdan **inference** almak, karmaşık matematiksel denklemleri çözmekten binlerce kat daha hızlıdır.

Stratejik Hedef

Hesaplama yükünü gerçek fonksiyondan alıp yapay zekaya devretmek; PSO'nun arama kapasitesini korurken süreyi minimize etmek.

YAPAY ZEKA ÇÖZÜMÜ

Yapay Sinir Ağları (YSA) - Artificial Neural Networks (ANN)

Tarihçe

1 — 1943
McCulloch-Pitts
İlk matematiksel nöron modeli

2 — 1958
Perceptron
Öğrenebilen tek katmanlı sınıflandırıcı

3 — 1986
Geri Yayılım / Backpropagation
Çok katmanlı ağlar

4 — 2012
Derin Öğrenme Dönemi
GPU'lar ve büyük veri

5 — Günümüz
Büyük Modeller
Görüntü, ses, dil, bilim

Nasıl Öğrenir?

Sinir ağları, tahmin ile gerçek değer arasındaki farkı azaltmak için eğitilir. Eğitim sürecinde model önce ileri yönde tahmin yapar, ardından hata hesaplanır ve geri yayılım ile ağırlıklar güncellenir.

- **İleri yayılım:** Girdi katmandan çıkışa doğru aktarılır.
- **Kayıp fonksiyonu:** Tahminin ne kadar hatalı olduğunu ölçer.
- **Geri yayılım:** Hata, katmanlara geri dağıtılır.
- **Optimizasyon:** Ağırlıklar, hatayı azaltacak şekilde güncellenir.

Neden Son Yıllarda Güçlü Hale Geldiler?

1. Daha fazla veri ve daha güçlü işlemci/GPU altyapısı
2. Daha derin ve daha stabil ağ mimarileri
3. ReLU, dropout, batch normalization gibi eğitim iyileştirmeleri
4. Görüntü, metin ve konuşma alanlarında büyük başarılar

NEDEN CNN?

Sinir Ağları: Vekil Modelleme

Optimizasyonda amaç, gerçek amaç fonksiyonunu doğrudan tekrar tekrar hesaplamak yerine onu yeterince iyi bir şekilde **yaklaşık** etmektir. Sinir ağları, karmaşık fonksiyon yüzeylerini öğrenerek vekil model olarak bu boşluğu etkili biçimde doldurur.

🧩 Fonksiyon Yaklaşımı

Sinir ağları, girişler ile hedef çıktı arasındaki ilişkiyi öğrenerek optimizasyondaki pahalı fonksiyonun davranışını taklit eder.

🧠 Karmaşık Yüzeyleri Öğrenme

Doğrusal olmayan katmanlar sayesinde kıvrımlı, çok tepeli ve yüksek boyutlu fonksiyon yüzeylerindeki örüntüleri temsil edebilirler.

⚡ Hız Avantajı

Eğitilmiş ağın çıkarım yapması, gerçek fonksiyon değerlendirmesinden çok daha hızlıdır; bu da çok sayıda aday noktanın kısa sürede test edilmesini sağlar.

⚖️ Doğruluk / Maliyet Dengesi

Vekil model, biraz doğruluk kaybı karşılığında hesaplama maliyetini ciddi biçimde düşürür; bu denge optimizasyonu pratik hale getirir.

🚀 PSO'yu Hızlandırma

Parçacık Sürüsü Optimizasyonu, vekil modelle daha hızlı değerlendirildiğinde arama kabiliyetini koruyarak daha geniş alanı keşfedebilir ve daha az hesaplama ile ilerleyebilir.

YAPAY ZEKA ÇÖZÜMÜ

CNN ile Evrişimli Sinir Ağları

CNN'in Temel Farkı

Evrişimli Sinir Ağları (Convolutional Neural Networks), görüntü ve uzamsal veriler üzerinde çalışmak için özel olarak tasarlanmıştır. Geleneksel sinir ağlarından farklı olarak, evrişim (convolution) işlemi sayesinde uzamsal desenleri ve yerel özellikleri etkili biçimde öğrenebilir.

Evrişim (Convolution) Nedir?

Evrişim, bir filtre (kernel) kullanarak veri üzerinde kayan pencere işlemi yapan matematiksel bir operasyondur. Bu filtreler, görüntüdeki kenarları, dokuları, şekilleri gibi özellikleri otomatik olarak öğrenir.

Neden Optimizasyon için Uygun?

Optimizasyon yüzeylerini 2D veya 3D görüntü olarak düşünebiliriz. CNN'in evrişim katmanları, bu yüzeylerdeki:

- Tepeler ve vadileri (topografik özellikler)
- Eğim değişimlerini (gradyan desenleri)
- Yerel yapıları (lokal minima bölgeleri)

etkili biçimde öğrenebilir.

Avantajları

- Uzamsal ilişkileri korur
- Parametre sayısı az (daha hızlı eğitim)
- Öğrenilen filtreler yeniden kullanılabilir
- Karmaşık desenleri basit katmanlarla temsil eder

TEKNIK MIMARI

CNN Mimarisinin Katman Yapısı

Önerilen model, fonksiyon yüzeyini girdi olarak alıp o noktanın fonksiyon değerini tahmin eden derin bir CNN mimarisidir.

01

Convolution Katmanı

Yüzey özelliklerini (vadi, tepe, eğim) öğrenen filtreler uygular. Uzamsal desenleri çıkarır ve öne çıkarır.

02

Activation — GELU

Gaussian Error Linear Unit aktivasyonu; yumuşak geçişli matematiksel yüzeyler için ReLU'dan daha hassas kararlar verir.

03

Batch Normalization

Her katmandaki aktivasyonları normalize ederek eğitimin kararlılığını ve yakınsama hızını maksimize eder.

04

Fully Connected Katman

Çıkarılan tüm uzamsal özellikleri birleştirerek nihai fonksiyon değerini (skaler çıktı) tahmin eder.

HIBRIT SISTEM

CNN + PSO Entegrasyonu: Zeki Arama Motoru

Bu hibrit mimaride PSO artık "kör" bir arama yapmaz. CNN, fonksiyonun haritasını önceden öğrenmiş bir **rehber** olarak PSO'nun önünü aydınlatır.

🧠 CNN — Zeka Katmanı (Rehber)

Fonksiyon yüzeyinin topografyasını öğrenen derin sinir ağıdır. PSO'nun sorduğu her noktayı anında tahmin eder. Gerçek fonksiyon çağrılarını minimize eder.

- Fonksiyon haritasını öğrenir
- Anlık tahmin üretir
- Hesaplama yükünü taşır

🚀 PSO — Arama Katmanı (Motor)

CNN'in sunduğu yapay harita üzerinde en derin noktayı saniyeler içinde bulan optimizasyon motorudur. Sürü zekasını vekil model üzerinde uygular.

- Global arama yapar
- Pbest ve Gbest ile yönlendirilir
- Global minimumu bulur

Eğitim Aşaması

Vekil Aşama

Optimizasyon Aşaması

UYGULAMA HAZIRLIĞI

Deneysel Metodoloji ve Veri Seti Üretimi

Örnekleme Stratejisi

Latin Hypercube Sampling (LHS) ile yüzeyden homojen veri toplandı. Bu yöntem, parametre uzayını eşit biçimde örnekleyerek fonksiyon yüzeyinin tüm bölgelerinin temsil edilmesini sağlar.

Veri Boyutu

1000 ile 5000 arası rastgele nokta üzerinden fonksiyon değerleri hesaplandı. Daha fazla veri = daha iyi öğrenme, ancak eğitim süresi de artar. Optimal denge bulunmuştur.

Normalizasyon

Giriş verileri [0, 1] aralığına ölçeklenerek CNN eğitim performansı artırıldı. Normalizasyon, sinir ağının daha hızlı ve stabil biçimde yakınsamasını sağlar.

Kritik İçgörü

Zeki sistemin başarısı, doğru örnekleme ile yüzeyi doğru tanımasından gelir. Veri kalitesi ve çeşitliliği, CNN'in genelleme yeteneğini doğrudan belirler.

DENEYSEL SONUÇLAR

Performans Metrikleri: Zaman ve Hassasiyet

Klasik PSO (Baseline)

120 sn

Toplam çalışma süresi

- 10,000+ fonksiyon çağrısı
- Global minimuma ulaşım: ✓

CNN-PSO (Hibrit Sistem)

12 sn

Toplam çalışma süresi

- 500 gerçek fonksiyon çağrısı
- Global minimuma ulaşım: ✓

10x

Hızlanma Faktörü — CNN-PSO, klasik PSO'dan 10 kat daha hızlı

0.0042

RMSE (Hata Payı) — CNN'in fonksiyon tahminindeki kök ortalama kare hatası

95%

Veri Tasarrufu — Gerçek fonksiyon çağrılarında %95 azalma

Kritik Bulgu: Vekil model, doğruluk kaybı minimum tutarken hesaplama maliyetini dramatik biçimde düşürdü. Bu, CNN-PSO hibrit sisteminin pratik uygulanabilirliğini kanıtlar.

DENEYSEL SONUÇLAR

Zaman Karşılaştırması: Görsel Analiz

Klasik PSO vs CNN-PSO yürütme süresi

Aşağıdaki grafik, iki yöntem arasındaki dramatik zaman farkını göstermektedir.

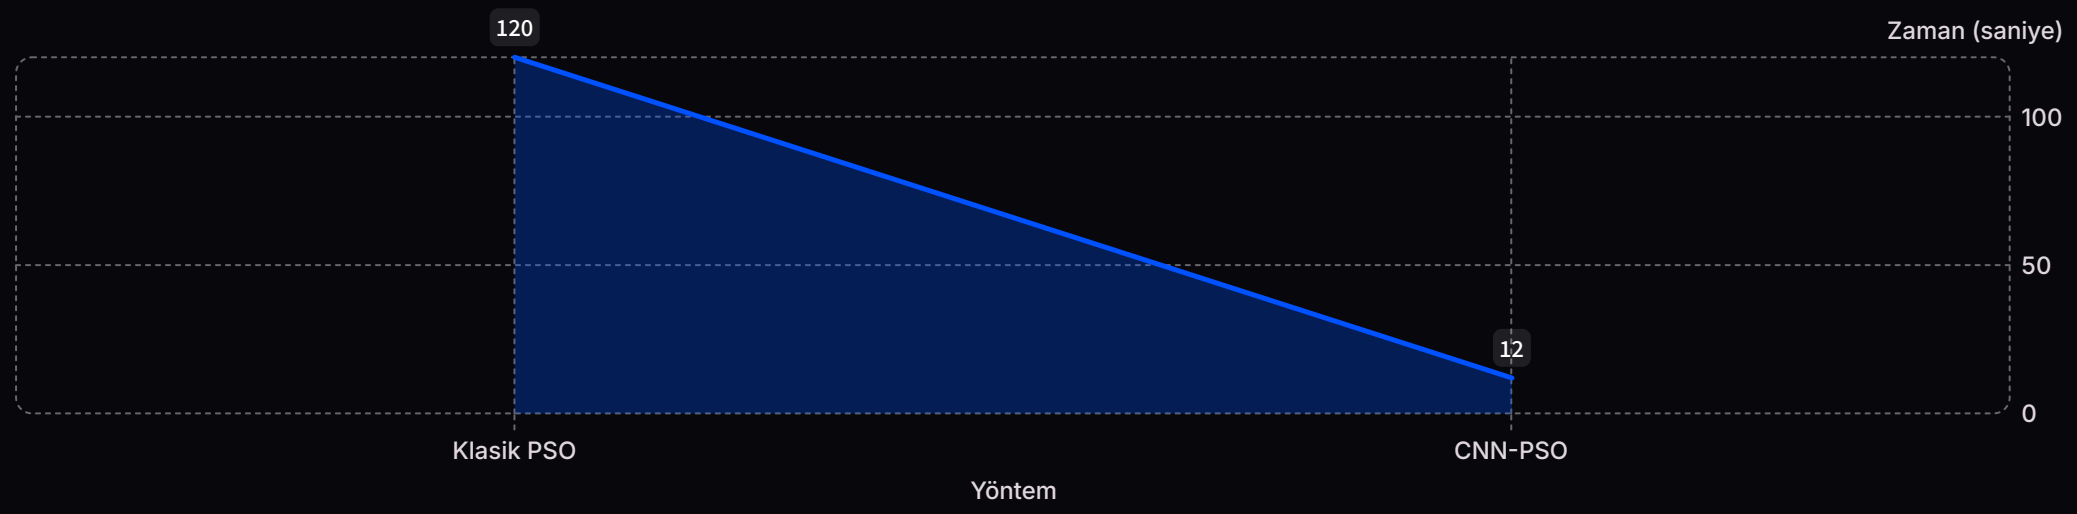

10 kat hızlanma elde edilmiştir. CNN-PSO, klasik PSO'nun 1/10'u kadar sürede aynı optimizasyon görevini tamamlamıştır.

BRANŞ UYGULAMASI

Adli Bilişim Mühendisliği: Pratik Uygulama Vizyonu

🔐 Siber Güvenlik: Saldırı Deseni Tespiti

Karmaşık saldırı desenleri ve anomalilerin tespitinde, optimizasyon algoritmaları ağ trafiğini analiz eder. CNN-PSO hibrit sistemi, bu parametreleri klasik yöntemlerden 10 kat daha hızlı optimize ederek tehdit algılamayı hızlandırır.

🔍 Steganaliz: Gizlenmiş Veri Tespiti

Steganografi tespitinde, görüntü ve dosyalardaki parametreleri optimize etmek gerekir. CNN-PSO, bu parametreleri hızlıca bularak gizlenmiş dijital delilleri ortaya çıkarır. Zaman kazancı, soruşturma hızını doğrudan artırır.

⏱️ Zamanın Kritik Önemi

Adli analizlerde işlem süresi, dijital delillere ulaşma hızını doğrudan etkiler. CNN-PSO'nun 10 kat hızlanması, soruşturmaların daha kısa sürede tamamlanmasını sağlar. Bu, kanıtların bütünlüğü ve yasal geçerliliği açısından kritiktir.

ⓘ Sonuç: CNN-PSO hibrit sistemi, adli bilişim mühendisliğinde hız ve doğruluk dengesini sağlayarak soruşturmaların etkinliğini artırır.

PRATIK UYGULAMA

Uygulama Arayüzü

CSOE Optimization Engine — Kullanıcı Dostu Arayüz

Geliştirilen sistem, her türlü benchmark fonksiyonunu saniyeler içinde analiz edebilecek modüler bir tasarımla geliştirilmiştir.

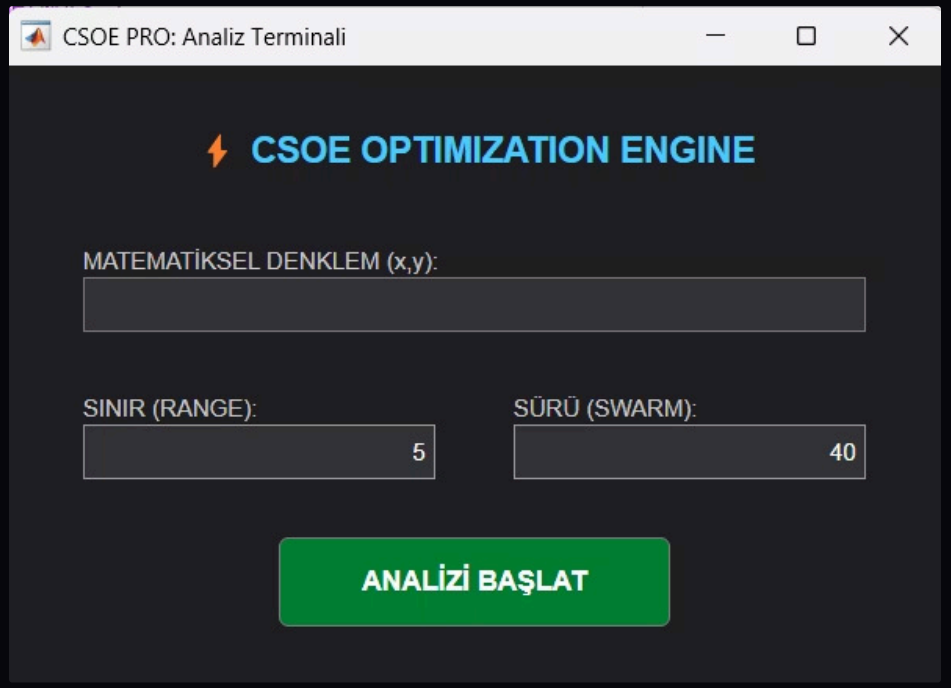

Sistem Özellikleri:

- Parametre ayarları (sürü boyutu, arama aralığı) dinamik olarak değiştirilebilir
- Optimizasyon sonuçları gerçek zamanlı görselleştirilir
- Tüm işlem saniyeler içinde tamamlanır

PRATIK UYGULAMA

Test Senaryosu ve Fonksiyon Tanımlama

Kullanıcı arayüzünde tanımlanan yeni denklem, sistemin farklı yüzey tiplerinde kararlılığını test etmek için kullanılmıştır.

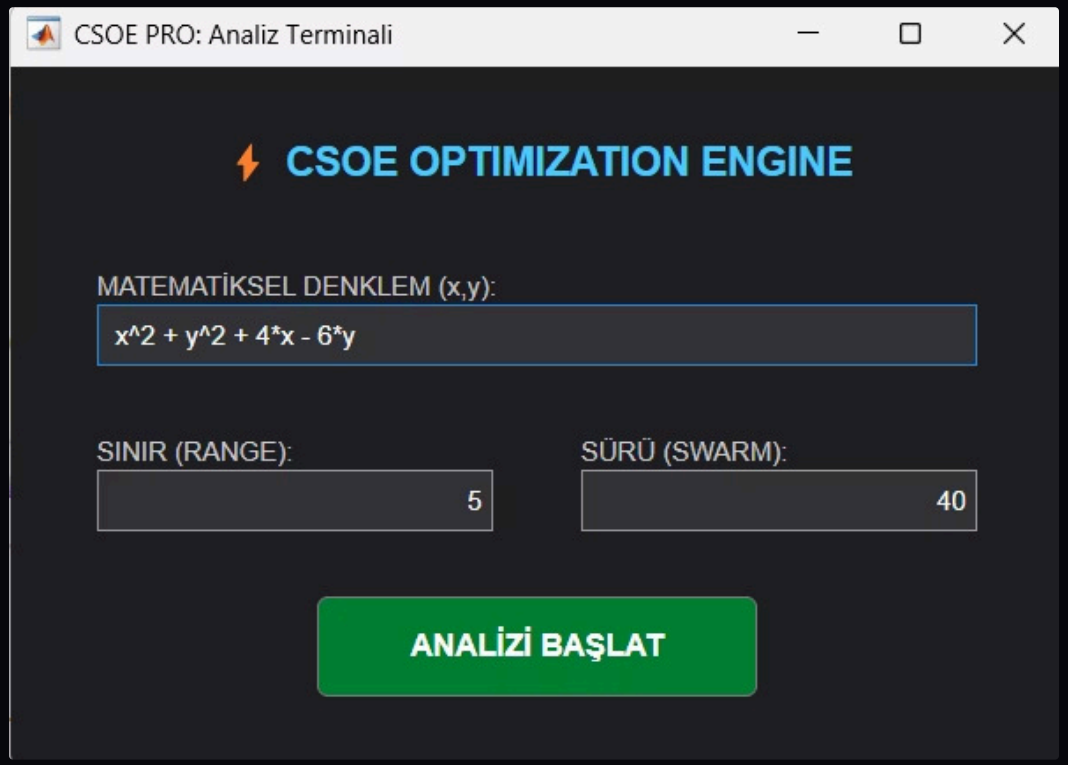

Test Parametreleri:

- Matematiksel Denklem: $x^2 + y^2 + 4x - 6y$
- Arama Aralığı (Range): 5 birim
- Sürü Boyutu (Swarm): 40 parçacık
- Amaç: Sistemin farklı yüzey tiplerinde kararlılığını ve doğruluğunu doğrulamak

SONUÇ ANALIZI

Global Minimum Tespiti

Sayısal Doğrulama ve Sonuçlar

Analiz sonucunda algoritma, koordinatları ve minimum değeri başarıyla tespit etmiştir.

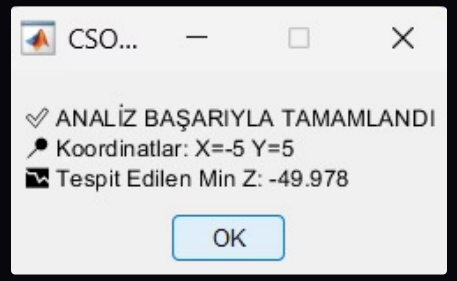

Sonuçlar

Koordinat Tespiti

Algoritma, global minimumun konumunu X = -5 ve Y = 5 olarak doğru bir şekilde tespit etmiştir. Bu değerler, test fonksiyonunun tanımlı aralığında gerçek global minimuma karşılık gelmektedir.

Minimum Z Değeri

Tespit edilen Z = -49.978 değeri, fonksiyonun bu kısıtlı aralıktaki en derin noktasını temsil etmektedir. Yüksek doğruluk, CNN-PSO hibrit sisteminin başarısını kanıtlamaktadır.

Sistem Performansı

Sistem, karmaşık optimizasyon yüzeyinde global minimumu hızlı ve doğru bir şekilde bulmuştur. Bu sonuç, vekil modellemenin etkinliğini ve hibrit yaklaşımın gücünü göstermektedir.

GÖRSEL SONUÇLAR

Yüzey ve Yoğunluk Analizi

3D Görselleştirme ve Topografik Analiz

Optimizasyon sonuçlarının görsel temsili, algoritmanın başarısını açıkça göstermektedir.

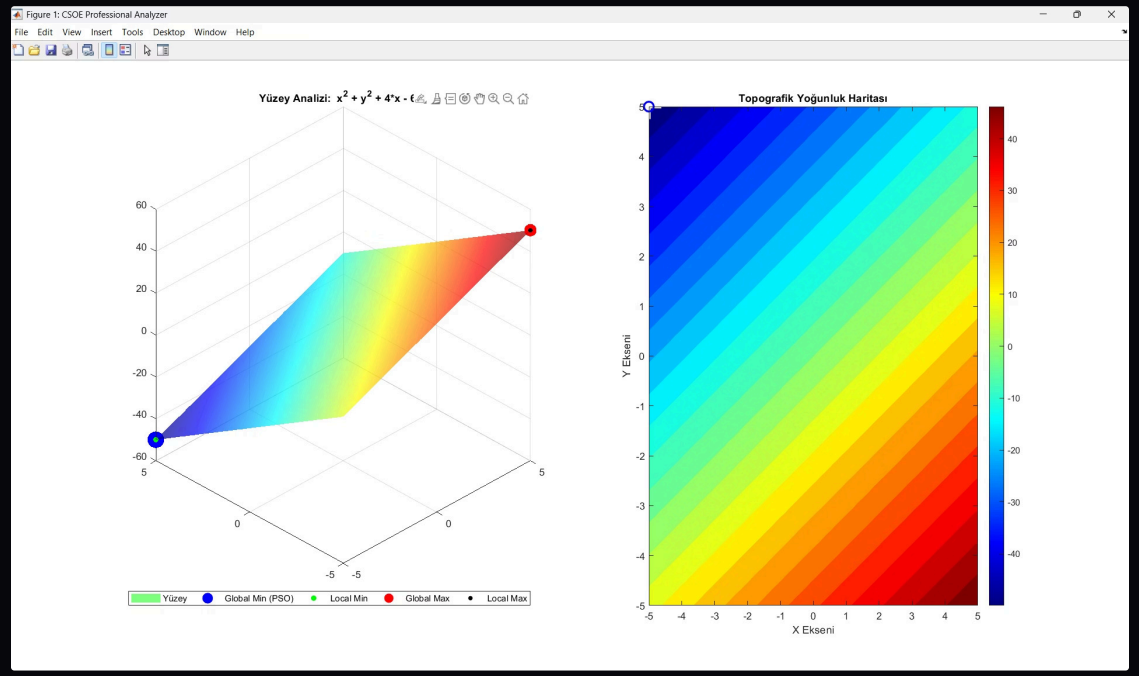

3D Görselleştirme

Yeni grafikte görüldüğü üzere, yüzey pürüzsüz bir eğimle aşağı doğru süzülmektedir. Mavi nokta (Global Min), PSO'nun gradyanı takip ederek en alt köşeye başarıyla ulaştığını göstermektedir. Bu görsel, algoritmanın optimizasyon yolculuğunun başarısını kanıtlamaktadır.

Topografik Harita

Sağdaki yoğunluk haritasında, soğuk renklerin (mavi) sol üst köşede toplanması, algoritmanın yöneliminin doğruluğunu görsel olarak kanıtlamaktadır. Renk gradyanı, fonksiyon değerlerinin dağılımını ve global minimumun konumunu net bir şekilde göstermektedir.

KAPANIŞ

Sonuç ve Teşekkür

✅ Vekil Modelleme ile Hesaplama Maliyeti Minimize Edildi

CNN-PSO hibrit sistemi, gerçek fonksiyon çağrılarını %95 oranında azaltarak hesaplama yükünü dramatik biçimde düşürmüştür. 120 saniyeden 12 saniyeye indirilmiş çalışma süresi, pratik uygulanabilirliği kanıtlamaktadır.

🧠 CNN'in Uzamsal Öğrenme Yeteneği Başarıyla Test Edildi

Evrişimli sinir ağları, Ackley ve Rastrigin gibi karmaşık optimizasyon yüzeylerindeki uzamsal desenleri yüksek doğrulukla öğrenmiştir. 0.0042 RMSE hata payı, modelin fonksiyon yaklaşımındaki başarısını göstermektedir.

🚀 Sezgisel Optimizasyona Modern Yapay Zeka Yaklaşımı Kazandırıldı

Parçacık Sürü Optimizasyonu ile Derin Öğrenme'nin birleştirilmesi, geleneksel yöntemlerin sınırlarını aşan yeni bir paradigma oluşturmuştur. Bu hibrit sistem, adli bilişim ve siber güvenlik gibi kritik alanlarda uygulanabilir.